

VERİ BİLİMİ PROJESİ RAPORU

İSİM-SOYİSİM : Walaa ALSABUNI

OKUL NUM. : 1306230115

TARİH : 02.07.2026

Problem tanımı

veri seti üzerindeki veri yükleme ,temizleme , hata kontrolü , oran gibi sonuçları öğrenmek amacıyla çeşitli model ve model karşılaştırmaları ile Keşifsel veri analizi yapıldı .

Kullanılan veri ve kaynağı :

- Breast Canser veri seti - sklearn.datasets.load_breast_cancer
- Proje **Colab notebook** üzerinden gerçekleştirildi
- Veri Boyutu : 569 Gözlem (Satır), 30 Özellik (Sütun)
- Hedef Değişken (Target): `malignant` (Kötü Huylu - 0) ve `benign` (İyi Huylu - 1)
- Lisans: Creative Commons Attribution 4.0 International (CC BY 4.0)

Kullanılan Kütüphaneler

Projenin çalıştırılması ve analizlerin yapılması için aşağıdaki Python kütüphaneleri kullanılmıştır:

- `numpy` (Sayısal hesaplamalar ve matris işlemleri)
- `pandas` (Veri manipülasyonu ve DataFrame yönetimi)
- `matplotlib` (Temel grafik ve görselleştirme çizimleri)
- `seaborn` (Gelişmiş istatistiksel veri görselleştirme)
- `scikit-learn` (Veri kümesi yükleme, model eğitimi ve başarı metrikleri)

Bulgular (analiz sorular&cevapları)

- **Hangi model en yüksek doğruluk oranına ulaştı?**
 - Lojistik Regrasyon modelidir . 0.9766 değeriyle en yüksek accuracy değerine ulaştı .
- **Precision ve Recall değerleri arasında anlamlı farklar var mı?**
 - Modelin malignant sınıfı için precision değeri 0.98 iken recall değeri 0.94 'e düşmüştür . bu durumda modelin kötü huylu tahminlerin neredeyse hepsinin doğru olduğunu gösterir ancak bir kısmını gözden kaçırdığını da gösteriyor .
- **Hangi model malign (kötü huylu) tümörleri tespit etmede daha başarılı ?**
 - Malign tümörleri tespit etmede en başarılı model lojistik regresyon olmuştur. Toplam 63 kötü huylu vakadan 61 tanesini doğru tahmin ederek %97 recall (duyarlılık) oranına ulaşmıştır ve kanserli hastaları en az gözden kaçıran modeldir.
- **Sağlık alanında Recall mi Precision mı daha kritik? Neden?**
 - Sağlık alanında kesinlikle recall metriği daha kritiktir. Çünkü düşük precision sağlıklı birine yanlışlıkla kanser teşhisi koyup ek testler yaptırır ancak hayati bir risk yaratmaz; düşük recall ise gerçek bir kanser hastasını gözden kaçırıp evine sağlıklı diye göndermek anlamına gelir ve tedavi gecikeceği için ölümcül sonuçlar doğurabilir.
- **Modeller arasında overfitting (aşırı öğrenme) belirtisi var mı ?**
 - Modeller arasında ciddi bir overfitting (aşırı öğrenme) belirtisi bulunmamaktadır. Eğitim ve test seti başarı oranları birbirine yakın ve dengelidir; karar ağacı modeli doğası gereği ezberlemeye biraz daha yatkın olsa da bu veri setinde genel doğruluk oranları makul sınırlar içinde kalmıştır.

Öğrenilenler

- Breast Cancer veri setini scikit-learn'den yükledim ve 569 örnek, 30 özellik ve 2 sınıf olduğunu öğrendim
- Sınıf dengesizliğinin neden önemli olduğunu anladım - Verideki %63-%37'lik dağılımı fark ederek, medikal projelerde sadece Accuracy (Doğruluk) metriğine güvenilemeyeceğini; **Recall (Duyarlılık)** ve **F1-Score** metriklerinin hayati olduğunu anladım.
- `df.isnull().sum()` ile de veride hiç eksik değer olmadığını saptamayı tecrübe ettim.
- normalizasyon/standartlaştırma (Feature Scaling) işlemlerinin önemini kavradım

Modeler arası accuracy karşılaştırma grafiği :

